

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Clasificación del nivel de operación aérea mensual por aeropuerto en Colombia

¿Puede una máquina anticipar si un aeropuerto operará bajo, medio o alto el mes que viene?

Inspira Crea Transforma

Proyecto Integrador — Maestría en ciencia de datos y analítica

Mauricio Correa · Alejandro Suarez · Verónica Zapata · Sara Cardona
Universidad EAFIT · Medellín, Colombia



Fuentes: [D1]

<

>

⌘ Usa flechas o haz clic

Contextualización



El problema



El reto

Colombia tiene más de 100 aeródromos activos. El volumen de operaciones varía mes a mes por temporadas, clima y demanda.



El costo

Sin anticipación, aerolíneas y operadores asignan personal, equipos y slots sin información predictiva.



La oportunidad

Los datos históricos de operaciones y variables meteorológicas contienen señal útil para clasificar el siguiente mes.

 La pregunta no es solo cuántos vuelos hubo: es cómo convertir historia operacional y clima en una decisión anticipada.

Inspira

Crea

Transforma

Fuentes:

[D1]

UNIVERSIDAD EAFIT | 2026 2/18

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Fuentes abiertas integradas

 Problema a resolver y fuentes de datos

- OurAirports

Dimensión aeroportuaria

Bronze → Silver
- Iowa Environmental Mesonet

METAR / ASOS histórico

Bronze → Silver → Gold
- Datos Abiertos Colombia · Operaciones

Operaciones aéreas

Bronze → Silver → Gold
- Datos Abiertos Colombia · Tráfico OD

Tráfico origen-destino

Bronze → Silver → Gold

S1

OurAirports

Códigos ICAO/IATA, coordenadas, tipo de aeropuerto y ubicación.

 **Abrir fuente**

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Fuentes abiertas integradas

 Problema a resolver y fuentes de datos

- OurAirports**

Dimensión aeroportuaria

Bronze → Silver
- Iowa Environmental Mesonet**

METAR / ASOS histórico

Bronze → Silver → Gold
- Datos Abiertos Colombia · Operaciones**

Operaciones aéreas

Bronze → Silver → Gold
- Datos Abiertos Colombia · Tráfico OD**

Tráfico origen-destino

Bronze → Silver → Gold

S3

Datos Abiertos Colombia · Operaciones

Llegadas, salidas y operaciones mensuales por aeropuerto.

 **Abrir fuente**

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Fuentes abiertas integradas

 Problema a resolver y fuentes de datos

- OurAirports

Dimensión aeroportuaria

Bronze → Silver
- Iowa Environmental Mesonet

METAR / ASOS histórico

Bronze → Silver → Gold
- Datos Abiertos Colombia · Operaciones

Operaciones aéreas

Bronze → Silver → Gold
- Datos Abiertos Colombia · Tráfico OD

Tráfico origen-destino

Bronze → Silver → Gold

S4

Datos Abiertos Colombia · Tráfico OD

Pasajeros, carga, origen, destino y empresas.

 **Abrir fuente**

Usa flechas o haz clic

Pipeline batch · PySpark en Databricks · 3 capas

Proceso de ingesta de datos

BRONZE

Raw

→

SILVER

Limpieza

→

GOLD

Modelo

OurAirports

146 aeropuertos · códigos ICAO/IATA · coordenadas.

IEM METAR

139 estaciones meteorológicas consultadas · histórico 2020–2025.

datos.gov.co

455.787 filas de tráfico OD · 550.724 filas de operaciones.

Decisiones técnicas clave

» Solo aeropuertos SK con ICAO válido → 66 usables

» IEM: mínimo 500 observaciones/aeropuerto → 48 con cobertura útil

» Unidad de análisis: icao_code + fecha_mes → granularidad mensual

» Separación temporal: train 2020-01 → 2023-08 · validación · test

Inspira

Crea

Transforma


Fuentes:

[D1]

[M1]

UNIVERSIDAD EAFIT | 2026 4/18

Arquitectura de datos
Arquitectura de referencia con Databricks




Idea central

La arquitectura organiza el proyecto como un flujo batch basado en Databricks y PySpark, desde fuentes abiertas hasta consumo analítico.

Arquitectura de referencia para almacenamiento de grandes datos con Databricks

Proyecto Integrador · Aeropuertos de Colombia · Lakehouse / Medallion Architecture



- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

 **Conjunto analítico final**

El dataset resultante

3254

registros aeropuerto-mes

46

aeropuertos con datos completos

72

meses 2020-01 a 2025-12

38

variables predictoras finales

Tipos de variables incluidas en el modelo

Historia operacional

Capturar inercia, tendencia y cambios bruscos en la operación mensual.

Demanda y conectividad

Distinguir hubs, aeropuertos regionales y operación con alta conectividad comercial.

Meteorología agregada

Convertir reportes METAR en indicadores mensuales de complejidad operativa.

Geografía y tipo

Incorporar ubicación, altitud y escala aeroportuaria como contexto estructural.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

 Preparación de datos

Imputación y tratamiento de faltantes

¿Qué se hizo con los datos faltantes?

Se aplicó una estrategia conservadora para mantener cobertura analítica sin introducir información futura ni reducir excesivamente el dataset.

01

Diagnóstico

Cobertura por aeropuerto-mes y familia de variables.

02

Imputación METAR

Mediana mensual del propio aeropuerto cuando existía historial suficiente.

03

Exclusión controlada

Registros sin target o sin información mínima fueron retirados.

3300

registros iniciales

3254

registros para modelado

46

aeropuertos con datos

Imputación meteorológica

Mediana mensual del mismo aeropuerto.

Consistencia temporal

No se usó información futura para completar meses pasados.


Control de leakage

El target futuro no se utilizó como predictor.

La imputación permitió conservar cobertura sin introducir información futura.

Análisis exploratorio

¿Quiénes mueven el cielo colombiano?




Hallazgos clave

- › SKBO concentra cerca del 29% de las operaciones acumuladas.
- › Los primeros aeropuertos explican gran parte del tráfico nacional.
- › La concentración obliga al modelo a aprender patrones por escala.

La actividad aérea colombiana no es homogénea: los hubs y aeropuertos regionales tienen dinámicas operativas distintas.

Análisis exploratorio

¿Quiénes mueven el cielo colombiano?



Hallazgos clave

- > SKBO concentra cerca del 29% de las operaciones acumuladas.
- > Los primeros aeropuertos explican gran parte del tráfico nacional.
- > La concentración obliga al modelo a aprender patrones por escala.

La actividad aérea colombiana no es homogénea: los hubs y aeropuertos regionales tienen dinámicas operativas distintas.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

EDA temporal



El tiempo y el COVID-19

- Pre-pandemia
- Minimo COVID
- Recuperación
- Nuevo máximo



EVENTO SELECCIONADO

Pre-pandemia

2020-01

81.582 operaciones

Nivel operativo previo al choque de 2020.

Franja roja: choque operacional COVID-19 2020.

📊 La serie evidencia el choque de 2020, la recuperación posterior y un nuevo techo operativo hacia 2024–2025.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19**
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

EDA temporal

El tiempo y el COVID-19

- Pre-pandemia
- Mínimo COVID
- Recuperación
- Nuevo máximo



EVENTO SELECCIONADO

Mínimo COVID

2020-05

12.946 operaciones

Punto mínimo de operaciones mensuales: 12.946 operaciones.

Franja roja: choque operacional COVID-19 2020.

La serie evidencia el choque de 2020, la recuperación posterior y un nuevo techo operativo hacia 2024–2025.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19**
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

EDA temporal



El tiempo y el COVID-19

- Pre-pandemia
- Mínimo COVID
- Recuperación**
- Nuevo máximo



EVENTO SELECCIONADO

Recuperación

2021-04

55.736 operaciones

Retorno progresivo hacia niveles cercanos a la pre-pandemia.

Franja roja: choque operacional COVID-19 2020.

📊 La serie evidencia el choque de 2020, la recuperación posterior y un nuevo techo operativo hacia 2024–2025.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

EDA temporal



El tiempo y el COVID-19

- Pre-pandemia
- Minimo COVID
- Recuperación
- Nuevo máximo



EVENTO SELECCIONADO

Nuevo máximo

2024-12

83.840 operaciones

Máximo operativo del periodo: 83.840 operaciones.

Franja roja: choque operacional COVID-19 2020.

📊 La serie evidencia el choque de 2020, la recuperación posterior y un nuevo techo operativo hacia 2024–2025.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Variable objetivo

El semáforo de operaciones



¿Cómo se define el target?

El nivel de operación se clasifica en tres clases usando percentiles calculados por tipo de aeropuerto.

Esto permite que un aeropuerto pequeño pueda ser “alto” aunque tenga menos vuelos que uno grande.

BAJO

≤ P33 de su tipo

MEDIO

P33–P66

ALTO







≥ P66

 Balance de clases: Bajo 32.9% · Medio 33.1% · Alto 34.0%.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

☀ EDA meteorológico


¿Importa el clima?



Correlación con target numérico

Rojo: positiva · Azul: negativa

- todos
- operacional
- meteorologico
- demanda




🗨 Las variables operacionales dominan, pero el clima aporta señal complementaria: visibilidad, IFR y temperatura separan parcialmente las clases.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 **Clima**
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

EDA meteorológico

¿Importa el clima?




🗨 Las variables operacionales dominan, pero el clima aporta señal complementaria: visibilidad, IFR y temperatura separan parcialmente las clases.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

EDA meteorológico

¿Importa el clima?




🔊 Las variables operacionales dominan, pero el clima aporta señal complementaria: visibilidad, IFR y temperatura separan parcialmente las clases.

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 **Clima**
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

☁ EDA meteorológico

¿Importa el clima?



🗨 Las variables operacionales dominan, pero el clima aporta señal complementaria: visibilidad, IFR y temperatura separan parcialmente las clases.

01 Proyecto

02 Problema

03 Fuentes

04 Pipeline

05 Arquitectura

06 Dataset

07 Imputación

08 EDA Top

09 COVID-19

10 Target

11 Clima

12 Características

13 Modelos

14 Resultados

15 Hipótesis

16 Conclusiones

17 Dashboard

18 Referencias

 **Entendimiento y preparación de datos**

Ingeniería de características

Historia operacional

Demanda y conectividad

Meteorología agregada

Geografía y tipo

Historia operacional

Capturar inercia, tendencia y cambios bruscos en la operación mensual.

Variables base

- operaciones_total
- operaciones_llegada
- operaciones_salida
- operaciones_por_destino

Ventanas temporales

- roll_mean_3
- roll_mean_12
- lag_1
- lag_3
- delta_1

Ejemplo de señal

- operaciones_vs_roll_mean_3
- operaciones_vs_roll_mean_12
- operaciones_delta_1



AeroDatos

01 Proyecto

02 Problema

03 Fuentes

04 Pipeline

05 Arquitectura

06 Dataset

07 Imputación

08 EDA Top

09 COVID-19

10 Target

11 Clima

12 Características

13 Modelos

14 Resultados

15 Hipótesis

16 Conclusiones

17 Dashboard

18 Referencias

<

>

✂ Usa flechas o haz clic

Entendimiento y preparación de datos

Ingeniería de características

Historia operacional

Demanda y conectividad

Meteorología agregada

Geografía y tipo

Demanda y conectividad

Distinguir hubs, aeropuertos regionales y operación con alta conectividad comercial.

Pasajeros

- pasajeros_total
- pasajeros_internacional_total
- pasajeros_por_operacion

Conectividad

- n_origenes_total
- n_destinos_total
- n_empresas_llegada
- n_empresas_salida

Carga

- carga_total_kg
- carga_kg_por_operacion
- carga_kg_por_operacion_lag_3

Dato crudo

→

Agregación mensual

→

Ventana temporal

→

Variable robusta

→

Modelo

Fuentes:

D1

Inspira

Crea

Transforma

UNIVERSIDAD EAFIT | 2026 12/18

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Entendimiento y preparación de datos



Ingeniería de características

- Historia operacional
- Demanda y conectividad
- Meteorología agregada
- Geografía y tipo

Meteorología agregada

Convertir reportes METAR en indicadores mensuales de complejidad operativa.

Condición atmosférica

- temp_media_c
- humedad_media_pct
- dewpoint_depression_c

Restricciones operativas

- visibilidad_min_sm
- prop_ifr_aprox
- prop_baja_visibilidad

Score adverso

- prop_lluvia
- prop_niebla
- prop_viento_fuerte
- meteo_adverso_score_roll_mean_12



Entendimiento y preparación de datos



Ingeniería de características

- Historia operacional
- Demanda y conectividad
- Meteorología agregada
- Geografía y tipo

Geografía y tipo

Incorporar ubicación, altitud y escala aeroportuaria como contexto estructural.

Ubicación

- latitude_deg
- longitude_deg
- region_name

Infraestructura

- elevation_ft
- type
- scheduled_service

Cobertura

- cobertura_metar_ratio
- tiene_metar_mes
- tiene_od_mes



- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Desarrollo de modelos

 Modelado · Comparación de algoritmos

Modelo	Macro F1	Accuracy	Balanced Acc
Regresión Logística	0.673	0.671	0.678
Extra Trees	0.808	0.806	0.814
Random Forest	0.860	0.859	0.863
XGBoost (Optuna)	0.876	0.875	0.873
✦ LightGBM (Optuna) — FINAL	0.876	0.868	0.870

📊 Validación temporal estricta: la selección se hizo sin mezclar meses pasados y futuros.


- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

LightGBM final

Análisis de resultados

Matriz de confusión normalizada

	Pred. bajo	Pred. medio	Pred. alto
Real bajo	86.9%	13.1%	0.0%
Real medio	7.1%	82.5%	10.3%
Real alto	0.0%	9.4%	90.6%



86.8%

Accuracy en test

87%

Balanced accuracy

86.8%


Macro F1

0%

Confusión bajo .. alto

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis**
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Hipótesis
Meteorología adversa sostenida



Lo que muestran los datos

- › meteo_adverso_score_roll_mean_12 aparece en el top de variables del modelo.
- › El score adverso promedio es más alto en aeropuertos de nivel bajo.
- › A 3 meses consecutivos, el efecto supera ampliamente el baseline aleatorio.

Los aeropuertos con score meteorológico adverso elevado durante 3 meses consecutivos tienen 74% de probabilidad de permanecer en nivel bajo — independientemente de su historial operacional.

 **Cierre analítico**

Conclusiones

- ✓ **El historial operacional domina**

Operaciones_total y sus medias móviles son las variables más importantes. El clima aporta señal complementaria pero real.
- ✓ **Limitación principal**

48 de 139 estaciones tienen cobertura METAR suficiente. Aeropuertos sin historial meteorológico dependen más de variables operacionales.
- ✓ **No hay confusión extrema**

El modelo nunca confunde bajo con alto. Los errores ocurren entre clases adyacentes.
- ✓ **LightGBM supera los baselines**

El baseline de persistencia temporal ronda 60%; el modelo final lo supera ampliamente.
- ✓ **Hipótesis**

Un score meteorológico adverso sostenido durante tres meses incrementa la probabilidad de permanecer en nivel bajo hasta 74%.

Dashboard interactivo

Los datos tienen la respuesta.

Cada mes, más de 80.000 operaciones despegan y aterrizan en Colombia. Detrás de cada vuelo hay personas, decisiones y recursos.

Ahora los invitamos a explorar el dashboard, donde la información operacional, meteorológica y territorial se presenta de forma interactiva.

 **Abrir dashboard interactivo**

<https://aeropuertos-pi.streamlit.app/>



Proyecto integrador · Aeropuertos Colombia

Radiografía operacional y meteorológica de aeropuertos Colombia

Exploración visual de operaciones, pasajeros, carga, conectividad y condiciones MI 2025. Incluye el choque COVID-19 y la recuperación posterior.

[Entrar al mapa interactivo](#)

 **Abrir dashboard**

- 01 Proyecto
- 02 Problema
- 03 Fuentes
- 04 Pipeline
- 05 Arquitectura
- 06 Dataset
- 07 Imputación
- 08 EDA Top
- 09 COVID-19
- 10 Target
- 11 Clima
- 12 Características
- 13 Modelos
- 14 Resultados
- 15 Hipótesis
- 16 Conclusiones
- 17 Dashboard
- 18 Referencias

Trazabilidad

 Referencias

[D1] Dataset del proyecto. Equipo del Proyecto Integrador. monthly_airport_model_dataset.csv. Dataset aeropuerto-mes, Colombia, 2020–2025, 46 aeropuertos y 3.254 registros. 2026.

[D2] Operaciones aéreas. Aeronáutica Civil de Colombia. Operaciones aéreas acumuladas en Colombia. Datos Abiertos Colombia.

[D3] Tráfico OD. Aeronáutica Civil de Colombia. Transporte Aéreo Comercial — Tráfico Origen-Destino. Datos Abiertos Colombia.

[D4] OurAirports. OurAirports. Airport and navaid data. Fuente para metadatos aeroportuarios.

[D5] IEM ASOS/METAR. Iowa Environmental Mesonet. ASOS/AWOS/METAR Data Download. Fuente para observaciones meteorológicas históricas.

[M1] CRISP-DM. Chapman et al. CRISP-DM 1.0: Step-by-step data mining guide. 2000.

[M2] LightGBM. Ke et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS, 2017.

[M3] Scikit-learn. Pedregosa et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.